

# ClimaObserver: Uma aplicação prática dos conceitos de Data Lake para ingestão de dados meteorológicos

Rafael M. d. Melo<sup>1</sup>, Luiz H. P. Pena<sup>1</sup>, Fernando R. Domingues<sup>1</sup>

<sup>1</sup>Universidade Federal de Uberlândia - Campus Monte Carmelo

{fernando.domingues, rafaelmelom.me, luiz.pena}@ufu.br

**Abstract.** *Data lakes are low-cost repositories that accommodate various types of data in their native format, whether structured or unstructured. This article explores the fundamental concepts, architecture, and advantages of Data Lakes. As a proof of concept, the ClimaObserver project was developed, an application that implements a Data Lake to collect and store climate data, captured through APIs. The solution demonstrates in practice how the schema-in-reading paradigm makes it easy to ingest data, enabling future analysis and decision-making. The technologies used include Python for data ingestion and storage in a file system that simulates a Data Lake, evidencing the flexibility of the approach.*

**Resumo.** *Data Lakes são repositórios de baixo custo que acomodam diversos tipos de dados em seu formato nativo, sejam eles estruturados ou não estruturados. Este artigo explora os conceitos fundamentais, a arquitetura e as vantagens dos Data Lakes. Como prova de conceito, foi desenvolvido o projeto ClimaObserver, uma aplicação que implementa um Data Lake para coletar e armazenar dados climáticos, capturados através de API. A solução demonstra na prática como o paradigma esquema na leitura torna fácil a ingestão dos dados possibilitando análises e tomadas de decisões futuras. As tecnologias utilizadas incluem Python para a ingestão de dados e armazenamento em um sistema de arquivos que simula um Data Lake, evidenciando a flexibilidade da abordagem.*

## 1. Introdução

Banco de dados são uma parte crucial para a sociedade atual, no cotidiano diversas tecnologias são movidas a essa tecnologia, como na obtenção de algum produto em um comércio, acessar um banco para suas operações com dinheiro, entre outros.

Esses exemplos de aplicações de banco de dados tradicionais, armazenando dados de forma textual ou numerica. Recentemente essa tecnologia avançou possibilitando o armazenamento de imagens, vídeos, audios, ampliando mais ainda as aplicações e utilidades do banco de dados. Agora possibilitando sistemas de análise de informações comerciais úteis. Resumidamente, banco de dados desempenham papel crítico em todas as áreas que computadores são usados. [ELMASRI 2011]

Em 2010, James Dixon, um dos fundadores e diretor de tecnologia da Pentaho inventou o termo Data Lake para descrever um novo tipo de banco de dados que armazena dados crus, em massa em um lugar. Esses dados sendo estruturados, semi-estruturados, não-estruturados.

Data Lakes são usados atualmente para coletar informações comportamentais de clientes de ecommerce, na exploração geográficas de companhias de gás, petróleo, em bancos etc. Devido a crescente área da Internet das Coisas (IoT), e também da proliferação de APIs, a quantidade de dados produzidos crescem em grande escala. Coletar esses dados se torna um desafio, visto que cada um pode ter sua própria estrutura e formato, impondo um desafio significativo aos banco de dados tradicionais, que exigem um esquema pré-definido. É nesse contexto, que o termo Data Lake vem a ser importante. Este trabalho propõe a aplicação desses conceitos através do projeto ClimaObserver, que visa criar um repositório centralizado para dados climáticos brutos, permitindo análises flexíveis no futuro. [Baum 2019]

## **2. Fundamentação Teórica**

### **2.1. Definição e Arquitetura**

Data Lakes são sistemas de armazenamento centralizado, utilizado para dados estruturados, não estruturados ou até semi-estruturados, em seu formato original. Diferentemente dos banco de dados tradicionais, os data lakes não requerem um formato pré definido, não se fazendo necessário para o armazenamento de dados, permitindo que os dados sejam guardados da maneira como foram capturados ou encontrados.[Geeks for Geeks 2025b]

Sua arquitetura é bem simples, começando pela fonte dos dados, seja eles em qualquer formato. A partir da origem, temos a camada de ingestão, onde os dados são extraídos, coletados e enviados para a camada de armazenamento. A camada de armazenamento é responsável por de fato guardar todos os dados, podendo utilizar diferentes tecnologias para que se consiga guardar diferentes tipos de dados, como por exemplo uma estrutura bem definida de diretórios, em um sistema de arquivos. E assim a última camada é responsável pelo consumo dos dados, já que até essa etapa, os dados já estão armazenados, em tese, em seu lugar correto. Durante essas camadas de ingestão, armazenamento e consumo, a depender da ferramenta, pode se ter alguns processos para ajudar gerenciar os dados do repositório.

### **2.2. Características Principais**

Visto sua definição acima, podemos concluir alguns pontos que caracterizam o data lake.

A começar pelo armazenamento flexível dos dados, levando em consideração a aceitação de diversos formatos de dados, preservando o contexto do dado, como exemplo, poderíamos guardar imagens, fotos, vídeos, textos, tabelas, backups, não necessitando dizer qual o formato deles.

Data Lakes também têm custo reduzido, e são mais escaláveis, isto é eles têm a habilidade de facilmente suportar dados cada vez maiores, claro que isso também leva em consideração o porte do sistema de armazenamento.

Podem ser projetados a partir de uma combinação simples de aplicações, como por exemplo ferramentas especializadas para processamento de dados, combinado com especializações de armazenamento possibilitando que os dados sejam transformados e acomodados com mais facilidade.

Geralmente, possuem também um gerenciamento de metadados, visando melhorar o entendimento e o uso dos dados no futuro.

### **2.3. Vantagens e Desvantagens**

As vantagens do uso dos Data Lakes estão intimamente relacionadas as suas características.

Data Lakes são uma ótima fonte para pesquisas e descoberta de dados, já que ele oferece uma análise e compreensão flexível a partir de dados brutos.

Oferece soluções escaláveis de armazenamento, sendo útil em contextos onde há crescente produção de dados, e grandes empresas. Também podendo considerar o fator presente, onde esses sistemas também são escalados para a nuvem.

A maneira como os dados são guardados, garante o benefício de que o custo será menor, podendo assim guardar grande quantidade de dados, com menor custo.

Sem uma estrutura rígida no momento de armazenamento dos dados, oferece uma flexibilidade e agilidade nesse processo.

Por fim, data lakes podem ser um ótima base para análise de dados avançada, ou até mesmo para alimentação de modelos de aprendizagem de máquina, tornando dados brutos em sacadas valiosas.

Mas eles também apresentam alguns desafios.

É difícil assegurar a qualidade dos dados, com muitos formatos diferentes, e gerenciamento não muito rígido.

Gerenciar metadados de grandes conjuntos de dados pode ser um pouco desafiador, sendo importante um armazenamento de metadados bem organizado.

Dados vindo de diversas fontes, e de diferentes formatos pode ser um pouco difícil para integrar tudo isso, lembrando que esses dados serão guardados separados no mesmo local.

Por fim, para correta implementação e melhoramento dos processos e infraestrutura, é de suma importância profissionais e tecnologias especializadas, já treinadas para lidar com tal situação.

### **2.4. Ferramentas e Tecnologias**

A organização Apache, que oferece diversos softwares e ferramentas úteis para desenvolvimento também oferece algumas ferramentas que podem vir a ser muito úteis durante o processo de projeto, criação, manutenção e melhoramento dos data lakes.

Apache Spark, como uma ferramenta para rápido processamento de dados em larga escala, oferecendo APIs em diversas linguagens de programação.[Geeks for Geeks 2025b]

Apache Hadoop, é um framework para armazenamento distribuído e processamento de grandes conjunto de dados utilizando um modelo simples de programação.[Geeks for Geeks 2025b]

Essas são apenas um pequeno exemplo de ferramentas onde conseguiríamos facilmente conectar os conceitos e criar um data lake, mas poderíamos ainda estender a ideia a ferramentas como o Pytorch e Tensorflow, para análise e montagem de modelos de aprendizagem de máquina.

## 2.5. Motivações históricas

Os Data Lakes, inicialmente eram feitos usando uma tecnologia baseada no Apache Hadoop, um framework de código aberto que distribui o armazenamento e o processamento de dados em data centers locais. Incluía também equivalentes a linguagem SQL, juntamente com tecnologias de processamento de dados em lote e interativo, utilitários de gerenciamento de cluster e outros componentes necessários para a plataforma de dados.

Infelizmente essas premissas não foram para frente devido a complexidade, vagareza à validação e aos esforços pesados de gerenciamento de sistemas. Hoje esse paradigma está revelando seu potencial através da computação em nuvem e os modelos de tecnologia legados em segundo plano.

Um terceiro paradigma do Data Lake surgiu com os Data Warehouse em nuvem. Essas soluções tornaram-se a base para o Data Lake atual, local onde dados estruturados ou semi-estruturados possa ser armazenado em um Data Warehouse ou em serviços de armazenamento de objetos associados. Os data lakes modernos combina essas opções de armazenamento de objetos para armazenar, carregar, integrar e analisar dados com facilidade.

Para Data Lakes não virarem Data Swamps, repositórios desorganizados de difícil compreensão e uso, os Data Lakes precisam guardar dados em formatos nativos, ser fácil de usar, possuir rotinas de gerenciamento e oferecer suporte a uma ampla gama de casos de uso de análise.

O motivo dos Data Lakes atuais não falharem, como no início de sua invenção, se deve a alguns desafios superados como a capacidade de acomodar grande volume de dados de diferentes formatos, fornecimento de recursos computacionais de acordo com a demanda atual, a possibilidade de múltiplos usuários terem acesso a mesma cópia de dados ao mesmo tempo, dados precisos e de qualidade, permissão a transação com múltiplas declarações e junções entre banco de dados diferentes e gerenciamento automático de performance, backups, segurança, permitindo os usuários focarem na parte da análise de dados.

Com um Data Lake moderno, feito na nuvem, é possível obter o poder de um Data Warehouse com a flexibilidade de um Data Lake. Com a maioria do armazenamento na nuvem, o ideal seria integrar esses dados na nuvem mesmo. Essa tecnologia em nuvem permite capturar, armazenar e descobrir trends e padrões. A preocupação de se o data center possui a capacidade de acomodar os dados não existe mais, nesse caso. Na nuvem, você pode se concentrar em escalar de forma econômica para lidar com volumes massivos de dados variados.

Um ponto importante a respeito dos dados a ser acolhidos é saber a respeito de sua origem, localização, quem tem acesso, como os dados são usados e como podem ser excluídos. Dados de baixa qualidade podem gerar decisões ruins, prejuízos e aumento de custos.

Além disso, é preciso ter em mente que a infraestrutura em nuvem pode falhar e ataques cibernéticos podem ocorrer, causando perdas, corrupções de dados. Sendo backups vitais e processos redundantes, uma análise podendo usar a cópia redundante para continuar com o processo. Desastres regionais devem também ser considerados, portanto

é útil os dados estiverem dispostos em diferentes regiões geográficas. É crucial que o processo de backup não influencie no desempenho das cargas de trabalho de produção. As regulamentações podem exigir que os dados sejam retidos por um tempo mínimo, o que reforça a necessidade de manter cópias de segurança. [Baum 2019]

### **3. Comparação com Tema Próximo**

Data Warehouse surgiu inicialmente com o propósito de resolver os mesmos problemas que os Data Lakes resolvem de acomodar dados em massa, com uma diferença de 40 anos de antecedência. Contudo, Data Warehouses não estavam mais conseguindo acomodar os novos tipos de projetos que estavam surgindo com seus modelos de rápida aquisição, chegando a quadrilhões de bytes facilmente, os Data Lakes pareciam uma melhor solução.

Uma das diferenças entre o Data Lake e o Data Warehouse é o momento da definição do esquema dos dados, no Data Warehouse os dados têm seu esquema definido no momento da escrita, ou seja, no momento em que os dados estão sendo inseridos no banco de dados, já existe um formato pré-definido para isso acontecer, como acontece em Bancos de Dados SQL, mas já no Data Lake o esquema dos dados é definido no momento de leitura dos dados, os dados são guardados apenas com base em estruturas de diretórios, como guardamos em nossos computadores, e na necessidade de leitura deles é definido o esquema, para termos algum padrão.

Além de todas as diferenças estruturais e arquiteturais, elas também se diferem em propósito da seguinte maneira, o Data Warehouse é pensado para além de suportar muitos dados, esses dados tem um destino, eles são usado para alimentar a tomada de decisão, para que esta seja informada. E mesmo que o Data Lake também seja projetado para receber muitos dados, no momento em que os dados são guardados eles não tem um destino certo, mas o armazenamento dos mesmo pode ser importante, para um movimento futuro.[Geeks for Geeks 2025a]

Mais diferenças entre os dois termos pode ser vista no quadro comparativo (Tabela 1).

## **4. Descrição da Aplicação Desenvolvida**

### **4.1. Proposta da aplicação e Objetivo**

A aplicação ClimaObserver foi desenvolvida pensando em demonstrar a construção de um Data Lake em pequena escala. O objetivo era captar e guardar dados meteorológicos da UFU, campus Monte Carmelo, mantendo sua estrutura original, a que foi enviada pela API. A aplicação está disponível publicamente para consulta <sup>1</sup>

### **4.2. Arquitetura e Tecnologias utilizadas**

Para a ingestão dos dados, utilizamos a linguagem Python com a biblioteca requests para o consumo dos dados da API da OpenWeather. Isso foi montado por meio de um simples script que foi automatizado com o serviço GitHub Actions para que fosse coletado dados de 5 em 5 minutos.

---

<sup>1</sup><https://github.com/rafaelmelom-dev/ClimaObserver>

**Tabela 1. Comparativo entre Data Warehouse e Data Lake (Adaptado de [Geeks for Geeks 2025b]).**

| Features                            | Data Warehouse                                                          | Data Lake                                                                  |
|-------------------------------------|-------------------------------------------------------------------------|----------------------------------------------------------------------------|
| Tipo de dados                       | Dados estruturados                                                      | Estruturados, Semi-estruturados de de-estruturados                         |
| Método de armazenagem               | Otimizados para dados estruturados com esquema definido                 | Guarda dados em sua forma crua, não processadas                            |
| Escalabilidade                      | Limitado devido as restrições dos dados estruturados                    | Altamente escalável, capaz de lidar com altos volumes de dados             |
| Eficiência de custo                 | Custoso para grande conjunto de dados devido ao estruturamento de dados | Eficiente devido a flexibilidade de armazenamento                          |
| Abordagem de processamento de dados | Dados devem ser estruturados antes da ingestão                          | Dados são guardados em forma crua, esquemas são aplicados durante análises |
| Performance                         | Otimizado para consultas rápidas em dados estruturados                  | Pode ser devagar devidos aos dados crus, não processados                   |

Para o armazenamento dos dados também utilizamos um repositório do GitHub, em que os dados eram guardados em estruturas de diretórios referentes ao tempo exato em que os dados foram coletados, toda essa parte foi feita por meio da própria linguagem de programação, com a simples estrutura de diretório `/data_lake/raw/weather/ufu/{ano}/{mês}/{dia}`, indicando primeiramente o diretório do Data Lake, depois **raw**, representando os dados brutos, **weather** para indicar que são dados em relação ao clima, **ufu** para indicar o local relacionado, e a partir disso temos o controle da data, importante metadado para consultas posteriores, por exemplo, se quisermos comparar o clima do mês de Janeiro com Agosto, ao invés de abrirmos todos os arquivos para vermos de quando são, já iremos direto para os diretórios desses meses.

#### 4.3. Funcionalidades Implementadas e Aplicação dos Conceitos

Como um projeto simples, o ClimaObserver tem apenas uma única funcionalidade, bem simples, que é coletar os dados, e os guardar no repositório. A tarefa de executar o projeto periodicamente faz parte do serviço GitHub Actions [GitHub 2025], em que foi feito um script para um workflow simples, termo usado para referenciar o fluxo da aplicação durante alguma ação no GitHub Actions.

Essas funcionalidades vão de encontro a um dos primeiros fundamentos do Data Lake, a Ingestão, onde os dados são capturados e redirecionados para armazenamento, importante também lembrar, que esses são dados brutos. Ao armazenar esses dados no formato JSON, formato vindo da API OpenWeather [OpenWeather 2025], sem transformá-lo, o ClimaObserver implementa um dos pilares do Data Lake, o esquema na leitura, já que em possíveis usos futuros, como por exemplo a média de temperatura do mês de Julho, o esquema para leitura de dados vai ser definido posteriormente, no momento da leitura, demonstrando sua flexibilidade.

O conceito de armazenamento foi diretamente aplicado por meio de uma estrutura de diretórios particionada, organizando os dados brutos para futuras consultas, uma prática essencial do Data Lake.

## 5. Considerações Finais

Data Lakes são componentes flexíveis para o armazenamento de dados, que apresentado por este presente artigo, se mostra importante para dados importantes mas que ainda não tem uma estrutura certa. Visto isso, são utilizados em diversos campos, com alta relevância para pesquisas, já que é claro a necessidade por dados brutos e ainda não transformados.

A construção do ClimaObserver solidificou o entendimento sobre alguns dos processos, principalmente para notarmos o quão um Data Lake é flexível, apenas necessitando que os dados sejam guardados, além também da ingestão, importante processo, já que sem ele não teríamos o que guardar.

Uma das principais dificuldades foi, no início pensarmos em uma simples aplicação, na concepção do projeto, tivemos algumas ideias mas posteriormente notamos que Data Lake não faz parte de uma aplicação de grande base como SQL, onde temos sistemas de SGBD rígidos, mas sobre filosofias e arquiteturas para resolver certos problemas, e eles podem sim ter estruturas robustas, mas não com uma ferramenta única que vamos ter, mas várias ferramentas especializadas que podem ser muito boas, como visto na seção de ferramentas. Então essa oferta de muitas ferramentas que ainda não sabíamos como funcionava, dificultou um pouco no começo, mas então depois decidimos fazer algo mais simples, apenas para demonstrar os processos de ingestão e armazenamento, sem muita governança sobre os dados.

Mas como um projeto simples, temos muita melhoria futura, começando pelo armazenamento, poderíamos elevar a estrutura para ferramentas especializadas, ou até para a nuvem, como os serviços que a AWS oferece, que poderia ser adaptado para fazermos diversos lakes, lugares onde colocaríamos os dados coletados. E a medida que muitos dados fossem coletados, também pode surgir a necessidade de processarmos esses dados, utilizando por exemplo o Apache Spark. São diversas possibilidades, também dependendo do que iremos colocar nesses data lakes.

## Referências

- Baum, D. (2019). *Cloud Data Lakes For Dummies®*, Snowflake Special Edition. John Wiley Sons, Inc., 1th edition.
- ELMASRI, Ramez; NAVATHE, S. B. (2011). *Sistemas de banco de dados*. Addison-Wesley, 6th edition.

Geeks for Geeks (2025a). Data warehousing. Acessado em 14 de setembro de 2025.

Geeks for Geeks (2025b). What is data lake ? Acessado em 12 de setembro de 2025.

GitHub (2025). GitHub Actions. Acessado em 14 de setembro de 2025.

OpenWeather (2025). OpenWeatherMap API. Acessado em 14 de setembro de 2025.